

Mini curso



Fernanda Abduche; Gilberto Rodrigues Liska; Josiane Rodrigues.

Visualização dos dados (ggplot 2)

Esse pacote é estruturado de forma que a “gramática” seja utilizada para um gráfico a partir de múltiplas camadas. As camadas serão formadas por dados, mapeamentos estéticos, transformações estatísticas dos dados, objetos geométricos (pontos, linhas, barras etc.) e ajuste de posicionamento. Além disso, existem outros componentes, como os sistemas de coordenadas (cartesiano, polar, mapa etc.) e, se for o caso, divisões do gráfico em subplots (facet). Um simples exemplo de múltiplas camadas seria um gráfico de pontos adicionado de uma curva de ajustamento.

É importante saber que um gráfico do ggplot2 pode ter mais de um objeto geométrico, cada um formando uma camada. Os objetos geométricos começam com a expressão **geom_** e são seguidos pelo tipo de objeto. Por exemplo, **geom_point()** para gerar um gráfico de pontos. Vamos, primeiramente, criar um gráfico com pontos a partir dos dados do Tab1. Porém antes de tudo é preciso que direcionar o R para ler o arquivo que deseja trabalhar, para informar ao R qual pasta ele deve ler. Exemplo 1:

```
setwd("C:/Users/Fernanda Abduche/Desktop/facul/grupo de estudo em estatistica")  
dados<-read.table("Tab1modificado.txt", h=TRUE)
```

```
library(ggplot2)  
g1 <- ggplot(dados, aes(y = Altura, x = Idade)) +  
  geom_point()  
g1
```



Como observado no outro exemplo, passamos um conjunto de dados para o ggplot. Depois, adicionamos uma camada de pontos, mapeando as variáveis para as posições de cada ponto nos eixos x e y, respectivamente, e a variável que deseja para a cor de cada ponto. Em seguida, alteramos a escala de cor, definindo seu título, os rótulos (labels) e os valores (values) para as cores. Por fim, definimos os títulos/rótulos do gráfico. Exemplo 2:

```
## discriminando sexo  
ggplot(dados) +  
  geom_point(aes(x = Idade, y = Altura, color = factor(Sexo)),  
             size = 3) +  
  scale_color_manual("Sexo",  
                    values = c("red", "blue"),  
                    labels = c("Feminino", "Masculino")) +  
  labs(title = 'Idade x Altura',  
        y = 'Altura',  
        x = 'Idade')
```

Exemplo 3:

```
## discriminando renda  
ggplot(dados) +  
geom_point(aes(x = Idade, y = Altura, color = factor(Renda)))  
+  
scale_color_manual("Renda",  
                    values = c("red", "blue", "green"),  
                    labels = c("Baixa", "Média", "Alta")) +  
labs(title = 'Idade x Altura',  
      y = 'Altura',  
      x = 'Idade')
```

Exemplo 4:

```
## alterando incrementos e rótulos no eixo x,y  
ggplot(dados) +  
  geom_point(aes(x = Idade, y = Altura, color = factor(Renda))) +  
  scale_color_manual("Renda",  
                    values = c("red", "blue", "green"),  
                    labels = c("Baixa", "Média", "Alta")) +  
  scale_x_continuous(name = "Idade", breaks = 15:30) +  
  scale_y_continuous(name = "Altura", breaks = seq(0,2,0.1),  
                    limits = c(1.5, 2))
```



Sendo também possível alterar as cores do gráfico, exemplo 5:

```
# alterar cor  
ggplot(dados) +  
  geom_point(aes(x = Idade, y = Altura, color = factor(Renda))) +  
  scale_color_manual("Renda",  
                     values = c("purple", "orange", "yellow"),  
                     labels = c("Baixa", "Média", "Alta")) +  
  labs(title = 'Idade x Altura',  
        y = 'Altura',  
        x = 'Idade')
```

Subplots

O `ggplot2` facilita a criação de subplots nos casos em que se deseja replicar o mesmo gráfico para um conjunto de valores de outra variável. As duas principais funções são **`facet_wrap()`** e **`facet_grid()`**. Para comparar essas relações para diferentes sexos, usamos a fórmula `~ Sexo`. Ou seja, indicamos que queremos quebrar os gráficos pela variável `Sexo`. Exemplo 6:

```
ggplot(dados) +  
  geom_point(aes(x = Idade, y = Altura),  
    size = 2) +  
  facet_wrap(~ Sexo)
```

Exemplo 7:

```
ggplot(dados, aes(x = Idade, y = Peso)) +  
  geom_point() +  
  facet_wrap(~ Renda)
```

Já o uso do **facet_grid()** é indicado para o cruzamento de variáveis. No exemplo abaixo, a relação entre as variáveis Idade e Peso será "quebrada" para grupos formados pelas variáveis **Sexo** e **Renda**. Exemplo 8:

```
ggplot(dados, aes(x = Idade, y = Peso)) +  
  geom_point() +  
  facet_grid(Sexo ~ Renda)
```

Exemplo 9:

```
ggplot(dados, aes(x = Idade, y = Peso)) +  
  geom_point() +  
  facet_wrap(~ Renda, scales = "free_y",  
    labeller = labeller(cut = c("Baixa", "Média", "Alta")))
```

Tipo de gráfico

Gráfico de dispersão: É bastante usado para verificar-se relações entre duas variáveis quantitativas. Exemplo 10:

```
library(tidyverse)  
## dispersao  
dados %>%  
  ggplot(aes(x = Idade, y = Peso)) +  
  geom_point() +  
  labs(x = "Idade",  
        y = "Peso (Kg)") +  
  theme_bw() #poderia trocar o tema aqui  
#theme_gray()
```

Gráfico de barras

Os gráficos de barras são geralmente utilizados para comparação entre categorias, ou seja, variáveis qualitativas. No ggplot2 podemos usar dois objetos geométricos distintos: **geom_bar** e **geom_col**. Exemplo 11:

```
## Grafico de barras  
ggplot(dados, aes(x = Sexo)) +  
  geom_bar() +  
  theme_minimal() #poderia trocar o tema aqui #theme_gray()
```



Há um detalhe importante para o **geom_bar**: o argumento **stat**. Por padrão, para este objeto geométrico, o valor de **stat** é **count** o que significa que ele fará uma contagem de elementos do eixo x e essa contagem será usada no eixo y. Então para que o y seja mapeado para uma variável do data.frame é necessário definir **stat = identity**. Exemplo 12:

```
# grafico de barras com renda e %de Sexo em cada  
coluna  
ggplot(dados, aes(x=Renda, y=Peso, fill=Sexo)) +  
  geom_bar(stat="identity")
```

Exemplo 13:

```
# grafico de barras com renda e %de Sexo em cada coluna  
ggplot(dados, aes(x=Renda, y=Peso, fill=factor(Sexo))) +  
  geom_col(position = "dodge") +  
  labs(title = "Renda x Peso",  
        x = "Renda",  
        y = "Peso",  
        fill = "Sexo") +  
  theme_minimal() #poderia trocar o tema aqui #theme_gray()
```

Histogramas

Os histogramas são utilizados para representar-se a distribuição de dados de uma variável quantitativa em intervalos contínuos. Esses intervalos são chamados de bins. Para cada bin, será apresentada a quantidade de valores que estão naquele intervalo, o **geom_histogram()** utiliza os mesmos elementos estéticos do **geom_bar()**. Exemplo 14:

```
## Histogramas  
#padrao do ggplot2  
ggplot(dados, aes(x = Peso)) +  
  geom_histogram(binwidth = 5, fill = 'dodgerblue',  
                 color = 'black') +  
  labs(title = "Distribuição do Peso (kg)",  
        x = "peso (kg)",  
        y = "Contagem") +  
  theme_minimal() #poderia trocar o tema aqui #theme_gray()
```

Transformando o histograma em proporção, exemplo 15:

```
#Transformando em proporção (Freq percentual)  
ggplot(dados, aes(x = Peso)) +  
  geom_histogram(aes(y = ..count../sum(..count..)),  
    binwidth = 5, fill = 'dodgerblue',  
    color = 'black') +  
  labs(title = "Distribuição do Peso (kg)",  
    x = "Peso",  
    y = "Proporção") +  
  scale_y_continuous(labels = scales::percent_format()) +  
  theme_minimal() #poderia trocar o tema aqui #theme_gray()
```



Veja no gráfico anterior que o rótulo do eixo x não está ajustado, vamos ajustar agora, pra isso precisamos calcular a amplitude da classe. Exemplo 16:

```
#numero de classes  
y=dados$Peso  
k=round(sqrt(length(y))); k  
#amplitude total  
A=max(y)-min(y); A  
# amplitude da classe  
c=A/(k-1); c  
Ll1=min(y) - c/2; Ll1  
LSk=max(y) + c/2; LSk
```

Exemplo 17:

```
dados$classe <- cut(dados$Peso, seq(0,100,by=c), right = FALSE)  
ggplot(dados, aes(classe))+  
  geom_histogram(stat= "count", aes(fill = ..count..))
```

Exemplo 18:

```
#eixo x arrumado, mas a escala é de densidade  
ggplot(data=dados, aes(Peso)) +  
  geom_histogram(aes(y =..density..),  
    breaks=seq(LI1, LSk, by = c),  
    col="red",  
    fill="green",  
    alpha=.2) +  
  geom_density(col=2) +  
  labs(title = "Distribuição do Peso (kg)",  
    x = "Peso",  
    y = "Proporção") +  
  scale_x_continuous(name = "Peso",  
    breaks = seq(LI1, LSk, by = c))
```

Exemplo 19:

```
#eixo x arrumado, frequência relativa  
ggplot(data=dados, aes(Peso)) +  
  geom_histogram(aes(y =..count../sum(..count..)),  
                 breaks=seq(Ll1, LSk, by = c),  
                 col="red",  
                 fill="green",  
                 alpha=.2) +  
  labs(title = "Distribuição do Peso (kg)",  
        x = "Peso",  
        y = "Proporção") +  
  scale_x_continuous(name = "Peso",  
                     breaks = seq(Ll1, LSk, by = c))
```

Exemplo 20:

```
#eixo x arrumado, frequência percentual  
ggplot(data=dados, aes(Peso)) +  
  geom_histogram(aes(y =..count../sum(..count..)),  
                 breaks=seq(LI1, LSk, by = c),  
                 col="red",  
                 fill="green",  
                 alpha=.2) +  
  labs(title = "Distribuição do Peso (kg)",  
        x = "Peso",  
        y = "Proporção (%)") +  
  scale_x_continuous(name = "Peso",  
                     breaks = seq(LI1, LSk, by = c)) +  
  scale_y_continuous(labels = scales::percent_format())
```


Freqpoly

A diferença dos histogramas para o **geom_freqpoly** é que este utiliza linhas para construir polígonos. Este utiliza os mesmo elementos estéticos do **geom_line()**. Exemplo 21:

```
#poligono de frequência  
ggplot(dados, aes(x = Peso)) +  
  geom_freqpoly(binwidth = 5) +  
  labs(title = "Distribuição do Peso (kg)",  
        x = "Peso",  
        y = "Contagem") +  
  theme_gray() #theme_minimal()
```

Boxplots

O boxplot é uma representação comum para apresentar-se a distribuição de uma variável a partir de seus quantis ou pode ser usado para verificar-se a distribuição de variável para um de conjunto de valores de uma segunda variável.



Fonte: Ciência de dados com R - introdução

Exemplo 22:

```
ggplot(dados, aes(x = Renda, y = Peso)) +  
  geom_boxplot() +  
  scale_x_discrete("Renda", limits = c("Baixa", "Media", "Alta"),  
                  labels = c("Baixa", "Média", "Alta")) +  
  labs(y = "Peso (kg)")
```

Exemplo 23:

```
## Boxplots  
ggplot(dados, aes(x = Renda, y = Peso)) +  
  geom_boxplot(fill = "dodgerblue") +  
  labs(y = "Peso (kg)",  
       x = "Renda",  
       title = "Distribuição do Peso") +  
  scale_x_discrete("Renda", limits = c("Baixa", "Media", "Alta"),  
                  labels = c("Baixa", "Media", "Alta")) +  
  theme_minimal() #poderia trocar o tema aqui #theme_gray()
```

Violinplots

Para ter uma visão da distribuição geral dos valores, podemos utilizar o **geom_violin()**. O violinplot baseia-se na densidade de probabilidade de uma variável contínua. Assim, é possível verificar-se em quais intervalos existe uma maior chance de ocorrência. Isto é representado pela parte mais larga do objeto. Exemplo 24:

```
#violin plot  
ggplot(dados, aes(x = factor(Sexo), y = Peso)) +  
  geom_violin(fill = "dodgerblue") +  
  labs(y = "Peso",  
        x = "Sexo",  
        title = "Distribuição do Peso") +  
  scale_x_discrete("Sexo", limits = c("Masculino", "Feminino"),  
                    labels = c("Masculino", "Feminino")) +  
  theme_gray() #theme_minimal()
```



*Obrigada pela
participação.*